

1

## Постановка задачи безусловной оптимизации

Пусть  $\mathbf{x} = (x_1, x_2, \dots, x_n) \in \Omega$  – вектор параметров оптимизации

$\Omega \in \mathbb{R}^n$  – множество допустимых решений,  $n \geq 1$

$f(\mathbf{x})$  – целевая функция,  $f: \mathbb{R}^n \rightarrow \mathbb{R}$

Тогда задачу безусловной оптимизации запишем следующим образом:

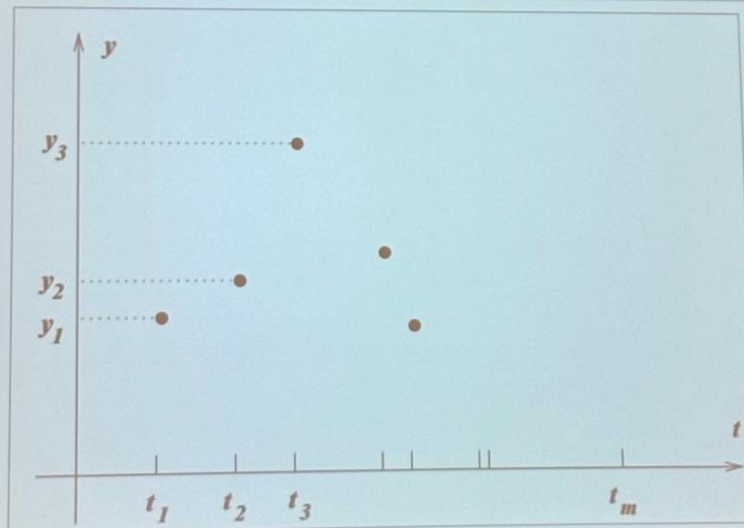
$$\min_{\mathbf{x} \in \Omega} f(\mathbf{x})$$

2

### Пример

Практическая задача безусловной оптимизации

Задача: имеется набор экспериментальных данных  $(t_i, y_i), i = 1 \dots m$ . Необходимо аппроксимировать геометрическое место точек исходных данных некоторой кривой  $f(\mathbf{x})$



Пусть из характера эксперимента известно, что данные могут соответствовать модели, заданной следующей функцией:

$$\phi(t; \mathbf{x}) = x_1 + x_2 e^{-(x_3 - t)^2 / x_4} + x_5 \cos(x_6 t),$$

где  $x_1, x_2, \dots, x_6$  - параметры модели.

Тогда расхождение экспериментально полученных данных  $(t_i, y_i)$ ,  $i = 1 \dots m$  со значением модели, полученным от функции  $\phi(t; \mathbf{x})$  при заданных параметрах  $x_1, x_2, \dots, x_6$ , может быть выражено как:

$$r_j(\mathbf{x}) = y_j - \phi(t_j; \mathbf{x}), \quad j = 1 \dots m$$

Следовательно, для решения задачи оптимизации необходимо минимизировать значения расхождений  $r_j(\mathbf{x})$ , а именно - найти минимум целевой функции  $f(\mathbf{x}) = r_1^2(\mathbf{x}) + \dots + r_m^2(\mathbf{x})$

Таким образом, задача безусловной оптимизации имеет вид:

$$\min_{\mathbf{x} \in \mathbb{R}^6} (r_1^2(\mathbf{x}) + \dots + r_m^2(\mathbf{x}))$$

В данном примере рассмотрена нелинейная задача наименьших квадратов (nonlinear least-squares problem)

Поиск оптимального решения начинается с выбранного начального значения  $\mathbf{x}_0$ . Выбор начального значения, как правило, основан на заведомо известной информации о поведении целевой функции или о положении её минимума.

Начиная со значения  $\mathbf{x}_0$ , алгоритм оптимизации генерирует последовательность итераций  $\{\mathbf{x}_k\}_{k=0}^{\infty}$  завершающуюся по достижении условия останова (будут разобраны позже). На каждой итерации алгоритм может использовать информацию о значении целевой функции на текущем и предыдущем(-их) шаге. На основе полученной информации алгоритм выполняет следующий шаг и выбирает следующее значение  $\mathbf{x}_{k+1}$ , в котором целевая функция будет меньше, чем на предыдущем (кроме немонотонных методов).

Существуют две стратегии выбора итеративного шага алгоритма оптимизации: стратегия линейного поиска и стратегия доверительной области.

График  
отобр.

соотв.  
Г. - 200

В.  $\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$

Бинарные  
отношения  
 $A = B$   
 $A \subseteq A \times A$

2) Существование  
 $f$  - ин. и сюр  
 $(\exists f^{-1})$

В рамках стратегии доверительной области информация, известная о целевой функции  $f(x)$ , используется для её аппроксимации с помощью некоторой функции  $m_k(x)$ , поведение которой рядом с точкой  $x_k$  схоже (совпадает) с целевой функцией. После аппроксимации, поиск минимума ведут уже для функции  $m_k(x)$ :

$$\min_p m_k(x_k + p),$$

где  $m_k(x)$  как правило, находят в виде:

$$m_k(x_k + p) = f_k + p^T \nabla f_k + \frac{1}{2} p^T B_k p$$

где  $f_k, \nabla f_k$  – значения целевой функции и градиента целевой функции в точке  $x_k$  соответственно,  $B_k$  – гессиан (или некоторое приближение гессиана) целевой функции в точке  $x_k$ .

Однако функция  $m_k(x)$  аппроксимирует целевую функцию достаточно точно лишь в некоторой окрестности точки  $x_k$ . По этой причине поиск минимума аппроксимированной функции ведут в некоторой доверительной области точки  $x_k$ . Как правило, доверительную область определяют как  $\|p\|_2 \leq \Delta$ , где  $\Delta > 0$  – радиус доверительной области.

При выборе длины шага оптимизации возникает конфликт интересов:

- Большая величина шага позволяет уменьшить количество обращений к целевой функции (снижение вычислительной сложности), но уменьшает точность алгоритма (можем «перескочить» минимум целевой функции).
- Малая величина шага обеспечивает большую точность, но увеличивает вычислительную сложность и количество итераций. В частности, наиболее точным выбором станет решение локальной задачи минимизации функции от длины шага при фиксированных значениях  $x_k$  и  $p_k$ :

$$\phi(\alpha) = f_k(x_k + \alpha p_k), \alpha > 0$$

Однако такой подход иррационален с точки зрения вычислительных и временных ресурсов.




10

## Методы линейного поиска

Длина шага. Пример

Оптимальный выбор длины шага оптимизации – глобальный минимум функции  $\phi(\alpha)$  при фиксированных  $x_k$  и  $p_k$ :

$$\phi(\alpha) = f_k(x_k + \alpha p_k), \quad \alpha > 0$$




11

## Методы линейного поиска

Длина шага. Условия Вольфе

Можно показать, что для того, чтобы длина шага  $\alpha_k$  алгоритма оптимизации обеспечивала достаточное уменьшение функции, должно быть выполнено следующее условие:

$$f(x_k + \alpha p_k) \leq \frac{f(x_k) + c_1 \alpha \nabla f_k^T p_k}{l(\alpha)}$$



Однако условия не обеспечивает гарантированный прогресс в поиске минимума, поскольку будет выполнено при любом достаточно малом значении шага  $\alpha_k$ .

Необходимо добавить условие, исключающее дробление шага.