

1

Математические основы многомерной оптимизации

Теорема. Пусть функция $f(x)$ ограничена снизу, дифференцируема на \mathbb{R}^n и ее градиент удовлетворяет условию Липшица с постоянной $L > 0$:

$$\|\nabla f(x') - \nabla f(x'')\| \leq L \|x' - x''\|, \quad \forall x', x'' \in \mathbb{R}^n$$

Тогда для любой начальной точки x^0 в итерационной процедуре:

$$x^{k+1} = x^k + \alpha y^k,$$

$$y^k = -\nabla f(x^k), \quad k = 0, 1, 2, \dots$$

можно выбрать такое число $\alpha > 0$, постоянное для всех k , что


$$\lim_{k \rightarrow \infty} \|\nabla f(x^k)\| = 0,$$

причем последовательность $\{x_k\}$ будет релаксационной.

2

Метод наискорейшего спуска Steepest Descent method

Идея подхода: при построении релаксационной последовательности используем антиградиент как направление спуска



Подготовительный этап:

Зададим начальное приближение x^0 и точность расчета ε :
 $\|\nabla f(x^i)\| < \varepsilon$.

Шаг 1:

Определим направление спуска и длину шага на текущей итерации:

$$y^i = -\nabla f(x^{i-1})$$

$$\alpha^i = \min_{\alpha \geq 0} f(x^{i-1} + \alpha y^i)$$

Вычислим приближение к точке минимума x^i :

$$x^i = x^{i-1} + \alpha^i y^i$$

Шаг 2:

Проверим выполнение условия останова:


Если $\|\nabla f(x^i)\| \geq \varepsilon$, то $i = i + 1$ и возвращаемся к шагу 1.

Иначе – завершаем поиск со значением $x^* = x^i$.

6

Метод сопряженных градиентов Conjugate Gradient (Fletcher-Reeves) method

Идея подхода: при построении релаксационной последовательности используем значение антиградиента на текущем шаге и направление спуска на предыдущем шаге



Подготовительный этап:
Зададим начальное приближение x^0 и точность расчета ϵ :
 $|\nabla f(x^1)| < \epsilon$
Определим первое приближение к точке минимума с шагом α^0 и направлением спуска s^0 .

$$s^0 = -\nabla f(x^0), \quad \alpha^0 = \min_{\alpha} f(x^0 + \alpha s^0), \quad x^1 = x^0 + \alpha^0 s^0$$

Шаг 1:

Определим весовой коэффициент w^1 , направление спуска s^1 и длину шага α^1 на текущей итерации:

$$w^1 = \frac{|\nabla f(x^1)|^2}{|\nabla f(x^0)|^2}, \quad s^1 = -\nabla f(x^1) + w^1 s^0, \quad \alpha^1 = \min_{\alpha} f(x^1 + \alpha s^1)$$

Вычислим приближение к точке минимума x^{i+1} :
 $x^{i+1} = x^i + \alpha^i s^i$

Шаг 2:

Проверим выполнение условия останова:

Если $|\nabla f(x^{i+1})| \geq \epsilon$, то $i = i + 1$ и возвращаемся к шагу 1

Иначе – завершаем поиск со значением $x^* = x^{i+1}$

При $i = n + 1$ итераций необходимо принять $x^0 = x^{n+1}$ и вернуться к шагу 1

9

Метод Полака-Райбера Polak-Ribière method

Идея подхода: вариация метода сопряженных градиентов, предполагающая альтернативный способ вычисления весовых коэффициентов:

$$w^i = \frac{\nabla^T f(x^i) [\nabla f(x^i) - \nabla f(x^{i-1})]}{\nabla^T f(x^{i-1}) s^{i-1}}$$

Подход Полака-Райбера позволяет избежать «перезапуска» алгоритма при достижении счетчиком итераций i значения $n + 1$. Это свойство обеспечивает большую эффективность метода Полака-Райбера для произвольных целевых функций.

1


Методы второго порядка. Идея подходов

Информация о значении функции и её градиента в методах оптимизации первого порядка позволяет определить направление оптимизации, но не даёт прямого ответа о величине шага для достижения минимума.

Методы оптимизации второго порядка используют информацию не только о градиенте, но и о матрице Гессе целевой функции. Методы второго порядка позволяют аппроксимировать целевую функцию в окрестности текущей точки как квадратичную функцию. Аппроксимирующую функцию $\varphi(x)$ можно получить при разложении целевой функции $f(x)$ в ряд Тейлора в окрестности точки x^k с исключением всех членов третьего и более высокого порядков:

$$\varphi(x) = f(x^k) + (\nabla f(x^k), (x - x^k)) + \frac{1}{2}((x - x^k), H(x^k)(x - x^k))$$


Результаты аппроксимации для методов первого и второго порядков:



3

Метод Ньютона Newton's Method

Идея подхода: при построении релаксационной последовательности используем значение антиградиента и матрицы Гессе целевой функции в точке.



Подготовительный этап:

Зададим начальное приближение x^0 и точность расчёта ε : $|\nabla f(x^i)| < \varepsilon$. Определим значения градиента $\nabla f(x^0)$, матрицы Гессе $H(x^0)$ и обратной матрицы $H^{-1}(x^0)$ целевой функции в точке x^0 :

$$\nabla f(x^0) = \left(\frac{\partial f(x^0)}{\partial x_1}, \frac{\partial f(x^0)}{\partial x_2}, \dots, \frac{\partial f(x^0)}{\partial x_n} \right), \quad H(x^0) = \left(\frac{\partial^2 f(x^0)}{\partial x_i \partial x_j} \right)_{i,j=1,n}$$

Шаг 1:

Вычислим приближение к точке минимума x^1 :

$$x^1 = x^0 - H^{-1}(x^0) \nabla f(x^0)$$

Определим значения градиента $\nabla f(x^1)$, матрицы Гессе $H(x^1)$ и обратной матрицы $H^{-1}(x^1)$ целевой функции в точке x^1 .

Шаг 2:

Проверим выполнение условия останова:

Если $|\nabla f(x^i)| \geq \varepsilon$, то $i = i + 1$ и возвращаемся к шагу 1.


Иначе - завершаем поиск со значением $x^* = x^i$.

10

Метод Ньютона-Рафсона

Newton-Raphson Method

Идея подхода: дополняем алгоритм метода Ньютона оптимальным выбором длины шага на каждой итерации.



Подготовительный этап:

Зададим начальное приближение x^0 и точность расчета ϵ . Определим значения градиента $\nabla f(x^0)$, матрицы Гессе $H(x^0)$ и обратной матрицы $H^{-1}(x^0)$ целевой функции в точке x^0 .

$$\nabla f(x^0) = \left(\frac{\partial f(x^0)}{\partial x_1}, \frac{\partial f(x^0)}{\partial x_2}, \dots, \frac{\partial f(x^0)}{\partial x_n} \right), H(x^0) = \left(\frac{\partial^2 f(x^0)}{\partial x_i \partial x_j} \right)_{i,j=1, \dots, n}$$

Шаг 1:

Вычислим приближение к точке минимума x^1 :

$$x^1 = x^0 - \alpha^1 H^{-1}(x^0) \nabla f(x^0),$$

где $\alpha^1 = \min_{\alpha \geq 0} f(x^0 - \alpha H^{-1}(x^0) \nabla f(x^0))$.

Определим значения градиента $\nabla f(x^1)$, матрицы Гессе $H(x^1)$ и обратной матрицы $H^{-1}(x^1)$ целевой функции в точке x^1 .

Шаг 2:

Проверим выполнение условия останова:

Если $|\nabla f(x^1)| \geq \epsilon$, то $i = i + 1$ и возвращаемся к шагу 1.

Иначе – завершаем поиск со значением $x^* = x^1$.

11

Метод хорд

Secant method

Идея подхода: для того, чтобы уйти от необходимости обращения ко вторым производным целевой функции, применим в методе Ньютона следующую аппроксимацию:

$$f'(x^i) \approx \frac{f(x^i) - f(x^{i-1})}{x^i - x^{i-1}}$$

Тогда на каждой итерации модернизированного метода Ньютона приближение к точке минимума будет найдено по следующему соотношению:

$$x^{i+1} = x^i - \frac{x^i - x^{i-1}}{f'(x^i) - f'(x^{i-1})} f'(x^i)$$

Следует отметить, что за отсутствие необходимости в информации о второй производной приходится платить большим количеством вычислений.